Rastgele Üretilen Arazide Serbest Eklemli Roketin Hassas İniş Kontrolü için PPO Tabanlı Pekiştirmeli Öğrenme ve Hedefli Ödül Şekillendirme

Ad SOYAD*

**Kurum Adı, Bölüm, Şehir, Türkiye — e-posta@kurum.edu.tr*

Özet

Dikey iniş yapabilen roketlerin son yaklaşma ve iniş evresi; doğrusal olmayan dinamikler, rüzgâr bozuntuları ve dar iniş toleransları nedeniyle zorlu bir kontrol problemidir. Bu çalışmada, MuJoCo fizik motoru üzerinde serbest eklemli (6 serbestlik dereceli) bir roketin, her bölümde rastgele üretilen engebeli arazi içindeki küçük bir iniş pedine hassas iniş yapması, Proksimal Politika Optimizasyonu (PPO) ile öğrenilmiştir. Başarı; pedin 30 cm yakınında, 0,48 m/s'nin altındaki dikey hızla ve dik duruşla 30 ardışık adım boyunca temasın korunması olarak tanımlanmıştır. Üç aşamalı eğitim izlenmiştir: 300 bin adımlık sıfırdan eğitim %34, 1 milyon adıma devam eğitimi %86 başarı oranı sağlamıştır. Kalan başarısızlıkların tamamına yakınının çarpma sınırının hemen üzerindeki temas hızlarından (sert iniş) kaynaklandığı belirlenmiş; zemine yakın bölgede 0,40 m/s üzerindeki dikey hız fazlasını cezalandıran hedefli bir ödül şekillendirme terimi eklenerek 500 bin adımlık ek eğitim yapılmıştır. Nihai politika, 200 bağımsız değerlendirme bölümünün tamamında başarılı iniş gerçekleştirmiş (%100), santimetre mertebesinde konum hassasiyeti ve sıfıra yakın temas hızı sergilemiştir. Sonuçlar, kalan hata modunu doğrudan hedefleyen küçük bir ödül düzenlemesinin, eğitim süresini uzatmaktan daha etkili olduğunu göstermektedir. Tüm eğitim, GPU gerektirmeden yaklaşık 30 dakikalık CPU süresinde tamamlanmıştır.

Anahtar Kelimeler: pekiştirmeli öğrenme, PPO, roket inişi, ödül şekillendirme, MuJoCo, hassas iniş kontrolü

Abstract

The terminal descent and landing phase of vertically landing rockets is a challenging control problem due to nonlinear dynamics, wind disturbances, and tight landing tolerances. In this study, Proximal Policy Optimization (PPO) is used to teach a free-joint (6-DoF) rocket, simulated in the MuJoCo physics engine, to perform precision landings on a small pad placed within procedurally generated rough terrain that is randomized in every episode. Success is defined as maintaining contact for 30 consecutive steps within 30 cm of the pad, below 0.48 m/s vertical speed, and in an upright attitude. A three-stage training regime was followed: training from scratch for 300k steps achieved a 34% success rate, and continued training to 1M steps achieved 86%. Nearly all remaining failures were traced to touchdown speeds just above the crash threshold (hard landings); a targeted reward-shaping term penalizing excess vertical speed above 0.40 m/s near the ground was added, followed by 500k additional steps. The final policy landed successfully in all 200 independent evaluation episodes (100%), with centimeter-level position accuracy and near-zero touchdown velocity. The results demonstrate that a small reward modification directly targeting the residual failure mode is more effective than simply extending training. All training completed in approximately 30 minutes of CPU time without a GPU.

Keywords: reinforcement learning, PPO, rocket landing, reward shaping, MuJoCo, precision landing control

1. GİRİŞ

Yeniden kullanılabilir fırlatma sistemlerinin yaygınlaşmasıyla birlikte, roketlerin dikey iniş evresinin güvenilir biçimde kontrol edilmesi güncel bir araştırma problemi hâline gelmiştir. İniş evresi; itki, yerçekimi, rüzgâr ve zemin temas kuvvetlerinin birlikte etkidiği, doğrusal olmayan ve kısıtlı bir kontrol problemidir. Klasik yaklaşımlar dışbükey optimizasyon tabanlı yörünge planlamasına dayanırken [6], pekiştirmeli öğrenme (RL) yöntemleri, modellenmesi güç bozuntular ve değişken çevre koşulları altında uçtan uca politika öğrenebilmeleri nedeniyle son yıllarda bu alanda giderek daha fazla incelenmektedir [7].

Bu çalışmada ele alınan problem, düz bir zemine iniş yapan basitleştirilmiş senaryoların ötesine geçmektedir: iniş bölgesi, her bölümde yeniden ve rastgele üretilen engebeli bir arazi içine yerleştirilmiş küçük bir hedef karodur (tile-pad). Ajanın; rüzgâr ve türbülans altında, yakıt kısıtıyla, araziye çarpmadan hedef karoya ulaşması ve dar hız/duruş toleransları içinde inişini kalıcı olarak sürdürmesi gerekmektedir.

Çalışmanın araştırma soruları şunlardır: RQ1: PPO ile eğitilen bir politika, rastgele arazide hassas roket inişini hangi başarı düzeyinde öğrenebilir? RQ2: Öğrenme doygunluğa yaklaştığında kalan hata modları, eğitim süresini uzatmakla mı yoksa hata modunu doğrudan hedefleyen ödül düzenlemesiyle mi daha verimli giderilir?

Çalışmanın başlıca katkıları şunlardır:

- MuJoCo tabanlı, rastgele arazi ve rüzgâr bozuntuları içeren, dar toleranslı bir 6-DoF roket iniş ortamında PPO ile %100 değerlendirme başarısına ulaşan bir eğitim reçetesi sunulmuştur.
- Başarısızlıkların tek ve iyi tanımlı bir hata moduna (çarpma sınırının hemen üzerindeki temas hızı) indirgendiği gösterilmiş; bu modu hedefleyen tek terimli bir ödül şekillendirmesinin, 500 bin adımda başarıyı %86'dan %100'e taşıdığı deneysel olarak ortaya konmuştur.
- Tüm sonuçların GPU gerektirmeden, yaklaşık 30 dakikalık CPU eğitimiyle tekrarlanabilir olduğu gösterilmiştir.

Bildirinin geri kalanı şu şekilde düzenlenmiştir: Bölüm 2 ilgili çalışmaları özetlemekte, Bölüm 3 benzetim ortamını ve yöntemi tanımlamakta, Bölüm 4 deneysel sonuçları sunmakta, Bölüm 5 bulguları tartışmakta ve Bölüm 6 sonuçları özetlemektedir.

2. İLGİLİ ÇALIŞMALAR

Roket ve uzay aracı inişinde klasik yaklaşım, iniş probleminin dışbükey optimizasyona indirgenerek çevrimiçi çözülmesidir; bu yaklaşım gerçek görevlerde kanıtlanmış olmakla birlikte, doğru dinamik model ve bozuntu kestirimi gerektirir [6]. Pekiştirmeli öğrenme tarafında, derin RL'in atari ve sürekli kontrol görevlerindeki başarısının ardından [5], Gaudet ve arkadaşları 6-DoF gezegen inişi için derin RL tabanlı güdüm politikaları önermiştir [7]. Politika gradyanı ailesinde PPO [1], kırpılmış amaç fonksiyonu sayesinde kararlı ve uygulaması basit bir yöntem olarak sürekli kontrol problemlerinde yaygın bir temel hâline gelmiştir.

Ödül şekillendirme literatüründe, potansiyel tabanlı şekillendirmenin optimal politikayı koruduğu bilinmektedir [8]. Pratikte ise seyrek başarı ödülleriyle eğitilen ajanlarda, kalan hata modlarını hedefleyen küçük ve yoğun ceza terimlerinin öğrenmeyi hızlandırdığı sıkça raporlanmaktadır. Bu çalışma, söz konusu pratiği sistematik bir vaka üzerinde belgelemekte; hata modu teşhisi ile hedefli ödül düzenlemesini birleştiren aşamalı bir eğitim reçetesinin etkinliğini, rastgele arazili hassas iniş görevi üzerinde nicel olarak göstermektedir. Benzetim altyapısı olarak MuJoCo [2], Gymnasium arayüzü [4] ve Stable-Baselines3 PPO gerçeklemesi [3] kullanılmıştır.

3. YÖNTEM

3.1. Benzetim Ortamı

Ortam, MuJoCo fizik motoru üzerinde serbest eklemli (free joint) bir roket gövdesi ve dört iniş ayağından oluşmaktadır. Her bölüm başında engebeli arazi yükseklik haritası rastgele yeniden üretilmekte ve iniş hedefi olarak, yüksekliği uygun hücreler arasından rastgele seçilen tek bir yeşil karo (tile-pad) atanmaktadır. Ajan; ana itki ile x ve y eksenlerindeki tork komutlarından oluşan 3 boyutlu sürekli eylem uzayına sahiptir. Gözlem vektörü; konum, doğrusal hız, gövde dik vektörü, açısal hız, hedefe göre konum farkı, rüzgâr bileşenleri ve kalan yakıt olmak üzere 18 boyutludur. Ortama sabit rüzgâr ve rastgele türbülans eklenmekte, bölüm uzunluğu en fazla 650 adımla sınırlandırılmaktadır.

3.2. Görev Tanımı ve Başarı Ölçütü

Başarılı iniş; ayakların yalnızca hedef karoya temas etmesi, ped merkezine yatay uzaklığın 0,30 m'nin altında olması, dikey hızın 0,48 m/s, yatay hızın 0,45 m/s ve açısal hızın 0,60 rad/s'nin altında kalması ve dik duruş skorunun 0,90'ın üzerinde olması koşullarının 30 ardışık benzetim adımı boyunca birlikte sağlanması olarak tanımlanmıştır. Dikey hızın 1,25 m/s'yi veya yatay hızın 1,05 m/s'yi aştığı temaslar ile gövde temasları çarpma sayılmakta ve bölümü sonlandırmaktadır.

3.3. Ödül Tasarımı ve Hedefli Şekillendirme

Temel ödül; hedefe ilerleme, ped merkezine uzaklık, hız ve açısal hız cezaları, dik duruş teşviki, yakıt tüketimi cezası ve adım başına küçük bir zaman cezasından oluşmaktadır. Başarılı iniş +210 (+ kalan yakıt bonusu), çarpma −160 uç ödülleriyle sonuçlanmaktadır. İlk 1 milyon adımlık eğitimin ardından yapılan hata analizi, başarısızlıkların sert inişlerde yoğunlaştığını göstermiş; bunun üzerine, roket hedefin 0,85 m üzerinden daha alçaktayken dikey hızın 0,40 m/s üzerindeki fazlasını −10 katsayısıyla cezalandıran hedefli bir şekillendirme terimi eklenmiştir. Eşik, güvenli iniş sınırı olan 0,48 m/s'nin bilinçli olarak altında seçilerek politikanın güvenlik marjı bırakması amaçlanmıştır.

3.4. Öğrenme Algoritması ve Eğitim Protokolü

Politika, Stable-Baselines3 kütüphanesinin PPO gerçeklemesiyle, iki gizli katmanlı çok katmanlı algılayıcı (MLP) politika ağı kullanılarak eğitilmiştir. Eğitim üç aşamada yürütülmüştür: (i) 300 bin adım sıfırdan eğitim, (ii) aynı ödül fonksiyonuyla 1 milyon adıma devam eğitimi, (iii) hedefli dikey hız cezası eklendikten sonra 500 bin adım ek eğitim (toplam 1,5 milyon adım). Kullanılan hiperparametreler Tablo 1'de verilmiştir.

Tablo 1. PPO hiperparametreleri

Hiperparametre	Değer
Politika ağı	MLP (64–64, tanh)
Öğrenme oranı	3×10^{-4}
Rollout uzunluğu (n_steps)	1024
Mini-batch boyutu	64
İndirim faktörü (γ)	0,99
Kırpma oranı (ε)	0,2
Donanım	CPU (GPU kullanılmadı)

4. DENEYSEL SONUÇLAR

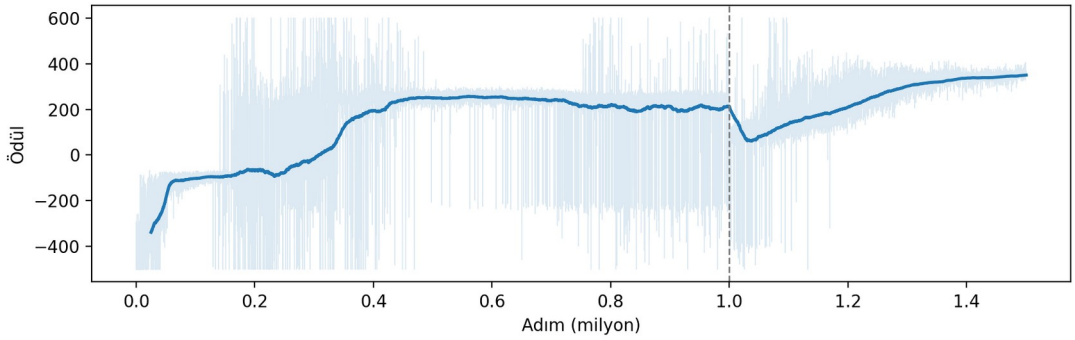
4.1. Aşamalı Eğitim Performansı

Her aşamanın sonunda politika, deterministik kipte 50 bağımsız bölümle değerlendirilmiş; nihai model ayrıca 200 bölümlük genişletilmiş bir değerlendirmeye tabi tutulmuştur. Her değerlendirme bölümünde arazi ve hedef karo yeniden rastgele üretilmiştir. Aşamalara göre sonuçlar Tablo 2'de özetlenmiştir.

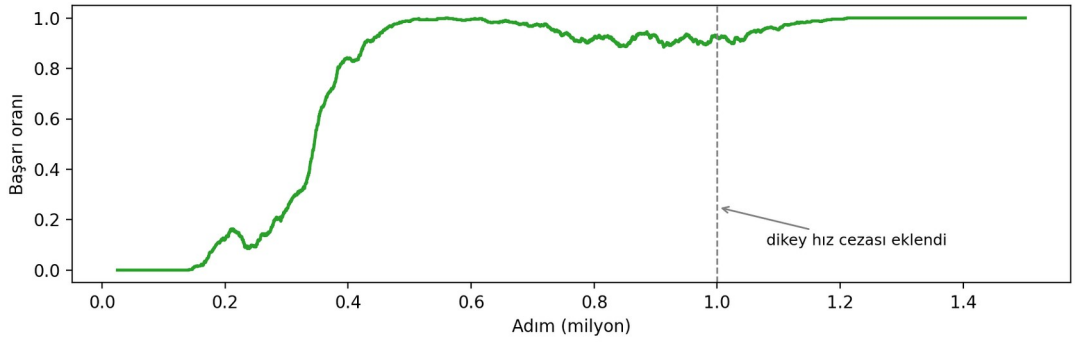
Tablo 2. Eğitim aşamalarına göre değerlendirme sonuçları

Aşama	Adım	Değişiklik	Başarı	Ort. ödül
1	0 → 300k	Sıfırdan PPO	%34	15,3
2	300k → 1M	Devam eğitimi	%86	191,7
3	1M → 1,5M	Dikey hız cezası	%100	362,9

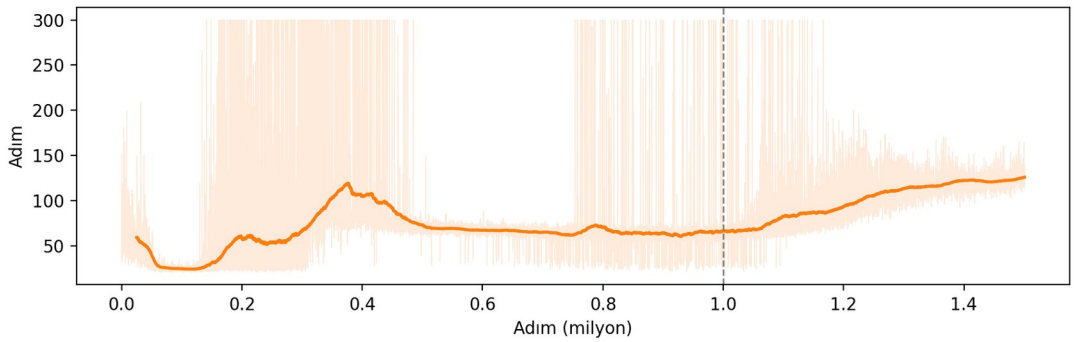
Öğrenme üç evrede gerçekleşmiştir. İlk 300 bin adımda ortalama bölüm ödülü −334'ten −36'ya yükselmiş, ajan öncelikle çarpmadan kaçınmayı öğrenmiştir. Devam eğitiminin hemen başında eğitim içi başarı oranının %20'den %76'ya sıçraması, 300 bin adımdaki politikanın yetkinlik eşiğinin hemen altında olduğunu göstermektedir. 1 milyon adım sonunda değerlendirme başarısı %86'ya ulaşmış, eğitim eğrisi doygunluk bölgesine yaklaşmıştır (Şekil 1–3).



Şekil 1. Eğitim boyunca bölüm ödülü (açık renk: ham değerler, koyu renk: kayan ortalama). Kesikli çizgi, 1 milyonuncu adımda hedefli dikey hız cezasının eklendiği anı göstermektedir.



Şekil 2. Eğitim boyunca kayan ortalama başarı oranı (423 bölümlük pencere). Ceza eklendikten sonra başarı oranı %100'e yakınsamaktadır.



Şekil 3. Eğitim boyunca bölüm uzunluğu (açık renk: ham değerler, koyu renk: kayan ortalama). Ceza sonrasında bölüm uzunluğunun artması, politikanın son yaklaşmada yavaşlayarak kontrollü iniş profiline geçtiğini göstermektedir.

4.2. Hata Modu Analizi ve Hedefli Ceza Etkisi

%86 başarı düzeyindeki politika incelendiğinde, başarısız bölümlerin hedefi bulamamaktan değil, pedin üzerine santimetre mertebesinde doğrulukla ancak çarpma sınırının hemen üzerindeki dikey hızla (~1,26 m/s; sınır 1,25 m/s) inilmesinden kaynaklandığı görülmüştür. Konum ve duruş kontrolünün çözülmüş, alçalma hızı yönetiminin ise eksik kaldığı bu tabloda, Bölüm 3.3'te tanımlanan hedefli ceza eklenmiş ve eğitim 500 bin adım sürdürülmüştür.

Cezanın etkisi davranış düzeyinde doğrudan gözlenmiştir: ortalama bölüm uzunluğu 72 adımdan 130 adıma çıkmış, yani politika son yaklaşmada alçalma hızını kırarak kontrollü iniş profiline geçmiştir. Bölüm ödülü standart sapmasının ±166'dan ±17,6'ya düşmesi, çarpma/başarı iki tepeli dağılımının ortadan kalktığını ve performansın bölümden bölüme kararlı hâle geldiğini göstermektedir.

4.3. Nihai Politikanın Değerlendirilmesi

Nihai politika, 200 bağımsız değerlendirme bölümünün tamamında başarılı iniş gerçekleştirmiştir (Tablo 3). Sıfır başarısızlık gözlemi, gerçek başarı oranının %95 güven düzeyinde en az %98,5 olduğu anlamına gelmektedir. Başarılı inişlerde ped merkezine sapma 1,5–7 cm aralığında (tolerans: 30 cm), temas anındaki dikey hız fiilen sıfır (~10^{-4} m/s; tolerans: 0,48 m/s) ve dik duruş skoru ~1,00 ölçülmüş; bölüm başına yakıt tüketimi %5–7 düzeyinde kalmıştır. Politika, ölçütleri sınırda geçmek yerine geniş güvenlik marjlarıyla sağlamaktadır.

Tablo 3. Nihai modelin 200 bölümlük deterministik değerlendirme sonuçları

Metrik	Değer
Başarı oranı	%100 (200/200)
Ortalama bölüm ödülü	362,9 ± 17,6
En düşük / en yüksek bölüm ödülü	317,3 / 427,2
Ortalama bölüm uzunluğu	129,6 adım
Toplam eğitim maliyeti	1,5M adım ≈ 30 dk CPU

5. TARTIŞMA

Bulgular iki araştırma sorusuna da doğrudan yanıt vermektedir. RQ1 için: PPO, rastgele arazili ve dar toleranslı hassas iniş görevini, görece küçük bir ağ ve mütevazı hesaplama bütçesiyle %100 değerlendirme başarısı düzeyinde öğrenebilmiştir. RQ2 için: %86'dan %100'e geçiş, eğitim süresini

uzatmaktan değil, hata modu teşhisine dayalı tek terimli bir ödül düzenlemesinden gelmiştir. Aşama 2'nin sonunda eğitim eğrisi düzleşmeye başlamışken, mevcut ödül altında sert inişler adım başına yalnızca yaklaşık −3,8'lik zayıf bir gradyan sinyali üretmekteydi; hedefli ceza bu sinyali güçlendirerek politikanın son metredeki davranışını değiştirmiştir.

Ödül standart sapmasındaki keskin düşüş (±166 → ±17,6), yöntemin yalnızca ortalama performansı değil, performans kararlılığını da iyileştirdiğini göstermektedir; güvenlik açısından kritik uygulamalarda bu ikinci özellik en az ilki kadar önemlidir. Öte yandan bölüm uzunluğunun 72'den 130 adıma çıkması, güvenlik ile iniş süresi (ve dolaylı olarak yakıt) arasında bir ödünleşim yaratmıştır; yakıt tüketimi %5–7 bandında kaldığından bu ödünleşim mevcut görevde ihmal edilebilir düzeydedir.

Çalışmanın sınırlılıkları şunlardır: (i) sonuçlar tek bir benzetim ortamına aittir ve gerçek sisteme aktarım (sim-to-real) incelenmemiştir; (ii) tek tohumlu eğitim koşuları kullanılmıştır, çoklu tohum istatistikleri raporlanmamıştır; (iii) değerlendirme deterministik politika ile yapılmıştır. Ayrıca ödül fonksiyonu değiştiği için aşamalar arası ödül değerleri doğrudan karşılaştırılabilir değildir; karşılaştırmalar başarı oranı üzerinden yapılmıştır.

6. SONUÇ

Bu çalışmada, rastgele üretilen engebeli arazideki küçük bir pede hassas roket inişi görevi PPO ile ele alınmış ve üç aşamalı bir eğitim reçetesiyle 200 bölümlük değerlendirmede %100 başarı oranına ulaşılmıştır. Temel bulgu yöntemseldir: öğrenme doygunluğa yaklaştığında, kalan başarısızlıkların tek bir hata moduna indirgenip bu modun tek terimli, hedefli bir ödül cezasıyla giderilmesi, eğitim bütçesini büyütmekten belirgin biçimde daha verimlidir. Gelecek çalışmalarda çoklu tohumlu istatistiksel doğrulama, alan rastgeleştirme ile sim-to-real aktarımı, yakıt-optimal iniş profilleriyle karşılaştırma ve daha dar toleranslara kademeli geçiş (müfredat öğrenmesi) planlanmaktadır.

KAYNAKLAR

[1] J. Schulman, F. Wolski, P. Dhariwal, A. Radford ve O. Klimov, "Proximal Policy Optimization Algorithms", arXiv:1707.06347, 2017.

[2] E. Todorov, T. Erez ve Y. Tassa, "MuJoCo: A physics engine for model-based control", IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS), s. 5026–5033, 2012.

[3] A. Raffin, A. Hill, A. Gleave, A. Kanervisto, M. Ernestus ve N. Dormann, "Stable-Baselines3: Reliable Reinforcement Learning Implementations", Journal of Machine Learning Research, c. 22, no. 268, s. 1–8, 2021.

[4] M. Towers vd., "Gymnasium: A Standard Interface for Reinforcement Learning Environments", arXiv:2407.17032, 2024.

[5] V. Mnih vd., "Human-level control through deep reinforcement learning", Nature, c. 518, s. 529–533, 2015.

[6] L. Blackmore, "Autonomous precision landing of space rockets", The Bridge (National Academy of Engineering), c. 46, no. 4, s. 15–20, 2016.

[7] B. Gaudet, R. Linares ve R. Furfaro, "Deep reinforcement learning for six degree-of-freedom planetary landing", Advances in Space Research, c. 65, no. 7, s. 1723–1741, 2020.

[8] A. Y. Ng, D. Harada ve S. Russell, "Policy invariance under reward transformations: Theory and application to reward shaping", International Conference on Machine Learning (ICML), s. 278–287, 1999.